

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Estudios Superiores Acatlán

Licenciatura en Actuaría

Modelo de Otorgamiento de Crédito con Política de Aprobación al 25 %

Scorecard de riesgo de crédito, comparación de modelos y
clasificación de créditos aprobados en Buenos y Malos

Administración Actuarial

Semestre 2026-1

Bárcena Romero, Orlando:

López Vélez, Ricardo Alejandro:

García Mercado, Karina:

Carvajal Aguilar, César Emir:

Flores, Frida:

Profesor(a) de la asignatura: _____

Ciudad de México, 11 de agosto de 2026

Resumen ejecutivo

Una institución de crédito personal recibe **292,849 solicitudes de crédito** (abril de 2007 a diciembre de 2015) y únicamente puede **originar el 25 % del monto total solicitado**. El objetivo del proyecto es construir un modelo de riesgo que seleccione *a cuáles* solicitudes otorgar crédito y que, de manera posterior, permita **clasificar los créditos aprobados entre Buenos y Malos**.

Dado que la base no reporta el estatus final del préstamo, se construyó el fenómeno de riesgo con un proxy de cargo a pérdida (*charge-off*) a partir de las variables de recuperación y cobranza reportadas por el originador. La muestra de desarrollo quedó conformada por **84,739 préstamos resueltos** (76,573 buenos y 8,166 malos; tasa de mora 9.6 %), excluyendo los 208,110 créditos aún activos (censurados) para no sesgar el análisis.

Se compararon tres metodologías bajo validación cruzada y validación *out-of-time* con métricas de negocio (KS, AUROC, Gini, Razón de Precisión, LogLoss y Brier):

- **Regresión Logística:** AUROC 0.698, Gini 0.396, KS 0.294 (OOT).
- **Random Forest:** AUROC 0.697, Gini 0.393, KS 0.294 (OOT).
- **XGBoost:** AUROC 0.690, Gini 0.380, KS 0.282 (OOT) y la mejor calibración (Brier 0.084).

Como modelo de gobierno se desarrolló un **scorecard de puntos** con Weight of Evidence e Information Value en cuatro variables interpretables (**grade**, plazo, ingreso/crédito y utilización rotativa), alcanzando AUROC 0.674, Gini 0.349 y KS 0.265 en la validación *out-of-time*.

Al simular la **política de aprobación del 25 % del monto solicitado** (US\$ 133.7 millones de presupuesto sobre US\$ 534.7 millones solicitados), el scorecard aprobó 9,447 solicitudes de las cuales **340 resultaron malas** (tasa de mora 3.6 %), frente a una tasa de 8.8 % si la selección fuera aleatoria y de 9.0 % si se aprobara todo. El modelo **reduce 2.5 veces la proporción de créditos incobrables** con el mismo presupuesto, lo que se traduce en un ahorro estimado de US\$ 6.5 millones en créditos mal aprobados.

Índice

Resumen ejecutivo	2
1. Introducción y contexto de negocio	4
1.1. Problema de negocio	4
1.2. Objetivos	4
1.3. Definición de Bueno y Malo	4
2. Descripción de los datos	5
3. Metodología	5
3.1. División de la muestra	5
3.2. Métricas de negocio	5
3.3. Scorecard de puntos	6
3.4. Política de aprobación al 25 %	6
4. Resultados	7
4.1. Comparativa de modelos	7
4.2. Scorecard de puntos	8
4.3. Política de aprobación al 25 %	9
5. Conclusiones y recomendaciones	9

1 Introducción y contexto de negocio

1.1 Problema de negocio

El otorgamiento de crédito es la actividad central de la banca personal: la rentabilidad depende de aprobar solicitudes que se pagarán y de rechazar aquellas que incumplirán. Cuando existe un **tope de originación**—como en este ejercicio, donde únicamente puede aprobarse el 25 % del monto total solicitado—el problema deja de ser *aprobar o rechazar una solicitud individual* y se convierte en un problema de **asignación de capital bajo presupuesto**: hay que elegir, entre todas las solicitudes, el subconjunto de mayor calidad esperada.

1.2 Objetivos

1. Construir una variable objetivo *Bueno/Malo* robusta a partir de la información de desempeño disponible.
2. Desarrollar y comparar modelos de probabilidad de incumplimiento (regresión logística, random forest y XGBoost) con métricas de negocio y validación *out-of-time*.
3. Convertir el mejor modelo en un **scorecard de puntos** interpretable (estándar de la industria bancaria).
4. Simular la política de aprobación del 25 % y clasificar los créditos aprobados en Buenos y Malos, cuantificando la mejora frente a políticas de referencia (aleatoria y aprobar todos).

1.3 Definición de Bueno y Malo

La base de datos no incluye el estatus final (e.g., *Fully Paid*, *Charged Off*) del préstamo, por lo que el desenlace debe inferirse. Lending Club registra el cargo a pérdida escribiendo el saldo principal a cero (`out_prncp` = 0) y reportando en `recoveries` y `collection_recovery_fee` las recuperaciones post-castigo. Con base en ello:

Resuelto : `out_prncp` = 0
Malo ($y = 1$) : `Resuelto` $\wedge$ (`recoveries` > 0 $\vee$ `collection_recovery_fee` > 0)
Bueno ($y = 0$) : `Resuelto` $\wedge$ $\neg$ Malo
Censurado : `out_prncp` > 0 (aún activo)

Los créditos censurados se **excluyen de la muestra de desarrollo**: incluirlos como “buenos” subestimaría la mora. Este proxy se valida por su consistencia externa: la tasa de mora es monótona creciente con la calificación interna de la institución (Tabla 1), lo que confirma que el fenómeno captura correctamente el riesgo.

Tabla 1: Tasa de mora por calificación interna (`grade`) sobre préstamos resueltos.

Grade	A	B	C	D	E	F	G
Tasa de mora (%)	3.26	6.68	9.70	13.98	18.31	23.85	22.94

2 Descripción de los datos

La base `loan_ejercicio.xlsx` contiene **292,849 solicitudes** y 42 variables (diccionario en `data/raw/LCDataDictionary.xlsx`). Los créditos se emitieron entre 2007 y 2015 con plazos de 36 o 60 meses; el corte de información es enero de 2016.

Tabla 2: Resumen de la muestra.

Concepto	n	%
Solicitudes totales	292,849	100.0
Créditos resueltos (Buenos + Malos)	84,739	28.9
Buenos	76,573	26.1
Malos	8,166	2.8
Créditos activos (censurados)	208,110	71.1
Muestra de desarrollo (emitidos < 2013-06)	38,722	—
Muestra out-of-time (2013-06 a 2015-01)	37,450	—

Variables de origenación. El modelado utiliza únicamente información disponible al momento de la solicitud (buró de crédito y aplicación): monto, plazo, tasa, calificación interna (**grade**), antigüedad laboral, vivienda, ingreso anual, verificación de ingreso, propósito, **dti**, delincuencias, cuentas abiertas, saldo y utilización rotativa, historial crediticio y tipo de aplicación. Las variables de desempeño (**total_pymnt**, **recoveries**, etc.) se usan *exclusivamente* para construir la variable objetivo y **nunca** como predictores, evitando *look-ahead bias*.

Ingeniería de características. Se derivaron dos razones estandarizadas: antigüedad del historial crediticio en años (**credit_history_yrs**) y cociente ingreso anual entre monto solicitado (**income_per_loan**), que resume la capacidad de pago relativa al compromiso. Para los modelos de aprendizaje estadístico, las variables muy sesgadas se transformaron con $\log(1+x)$ y se winsorizaron colas extremas.

3 Metodología

3.1 División de la muestra

Se aplicó una división **temporal** (*no aleatoria*) para simular el uso real del modelo:

- **Desarrollo:** créditos resueltos emitidos antes del 2013-06-01 ($n = 38,722$, mora 12.1 %).
- **Out-of-time (OOT):** créditos resueltos emitidos entre 2013-06-01 y 2015-01-01 ($n = 37,450$, mora 9.0 %). Nunca vistos durante el ajuste.

La validación OOT replica la condición industrial *scorecard truncada*: el modelo se calibra con vintages maduros y se evalúa su poder sobre vintages posteriores (estabilidad temporal).

3.2 Métricas de negocio

Las métricas utilizadas son las estándar de riesgo de crédito. Para un score s (mayor $\Rightarrow$ menor riesgo) y clases $y \in \{0, 1\}$ (1 = malo):

- **KS (Kolmogorov–Smirnov)**: máxima separación entre las funciones de distribución acumulada de buenos y malos; $KS = \max_s |F_{\text{malos}}(s) - F_{\text{buenos}}(s)|$. En scorecards de otorgamiento se busca $KS \geq 0,30$.
- **AUROC**: probabilidad de que un buen pagador obtenga mejor score que uno malo; $AUROC = P(s_{\text{bueno}} > s_{\text{malo}})$.
- **Gini**: $Gini = 2 \cdot AUROC - 1$.
- **Curva CAP y Razón de Precisión (AR)**: fracción acumulada de malos capturada por los primeros porcentajes de la población ordenada; mide la ganancia de concentración frente a la selección aleatoria.
- **Lift y tasas por decil**: mora observada en cada decil de score; mide la utilidad operativa de ordenar solicitudes.
- **LogLoss y Brier**: calidad de calibración de las probabilidades pronosticadas.

3.3 Scorecard de puntos

El modelo de gobierno se construyó con la metodología tradicional de scorecards:

1. **Coarse classing**: cada variable se agrupa en tramos.
2. **Weight of Evidence** por tramo $WoE_i = \ln\left(\frac{\%Malos_i}{\%Buenos_i}\right)$, e **Information Value** $IV = \sum_i (\%Malos_i - \%Buenos_i) WoE_i$ para seleccionar variables.
3. **Regresión logística** sobre la matriz de WoE (un coeficiente por variable).
4. **Conversión a puntos** con el parámetro PDO (puntos para duplicar las odds; aquí 20):

$$\ln(\text{odds}) = \beta_0 + \sum_j \beta_j WoE_j, \quad s = \text{offset} - \underbrace{\frac{PDO}{\ln 2}}_{\text{factor}} \cdot \ln(\text{odds})$$

El punto base se fija en 656 con odds bueno/malo de 50:1.

3.4 Política de aprobación al 25 %

La simulación opera sobre la muestra OOT ($n = 37,450$; monto solicitado US\$ 534.7 millones):

1. Se ordenan las solicitudes por score (menor riesgo primero).
2. Se aprueban las solicitudes hasta agotar el **presupuesto del 25 % del monto solicitado** (US\$ 133.7 millones); como los montos son indivisibles, se toma la solicitud completa que no exceda el remanente.
3. Cada solicitud aprobada se clasifica con su desenlace real en **Buena** (pagada) o **Mala** (castigada).

Se comparan tres políticas: la del **scorecard**, la **aleatoria** y la de **aprobar todos** (referencia de cartera sin selección).

4 Resultados

4.1 Comparativa de modelos

La Tabla 3 resume las métricas de negocio de los tres modelos, tanto en validación cruzada 5-fold sobre desarrollo como en la validación out-of-time.

Tabla 3: Métricas de negocio por modelo. CV = validación cruzada 5-fold en desarrollo; OOT = validación out-of-time (vintages 2013-06 a 2015-01).

	KS	AUROC	Gini	AR	LogLoss	Brier
<i>Validación cruzada (CV)</i>						
Regresión Logística	0.289	0.701	0.401	0.401	0.626	0.218
Random Forest	0.286	0.696	0.392	0.392	0.583	0.199
XGBoost	0.285	0.697	0.394	0.394	0.341	0.100
<i>Validación out-of-time (OOT)</i>						
Regresión Logística	0.294	0.698	0.396	0.396	0.703	0.251
Random Forest	0.294	0.697	0.393	0.393	0.639	0.224
XGBoost	0.282	0.690	0.380	0.380	0.298	0.084




Figura 1: Curvas ROC sobre la muestra out-of-time. Los tres modelos muestran poder discriminativo equivalente en ranking; XGBoost destaca en calibración.

4.2 Scorecard de puntos

La selección de variables por Information Value y depuración de colinealidad retiene **cuatro atributos**: calificación interna (**grade**), plazo (**term_months**), ingreso por peso de crédito (**income_per_loan**) y utilización rotativa (**revol_util**). La Tabla 4 muestra los puntos asignados por tramo (punto base 656.1).

Tabla 4: Scorecard de puntos (PDO = 20). El score final del solicitante es $656.1 + \sum$ puntos de sus atributos.

Atributo	Tramo	Puntos	Atributo	Tramo	Puntos
Grade	A	+26.4	revol_util (%)	< 20	+1.9
	B	+8.2		20–36	+1.3
	C	−3.3		36–48	+0.8
	D	−11.7		48–58	+0.3
	E	−21.9		58–67	−0.3
	F	−31.7		67–76	−0.6
	G	−27.9		76–86	−1.0
ingreso/crédito	<2.9	−5.8	Plazo	≥ 86	−1.6
	2.9–3.6	−2.3		36 meses	+3.6
	3.6–4.4	−0.6		60 meses	−11.7
	4.4–5.3	+0.7			
	5.3–6.7	+1.8			
	6.7–8.6	+2.7			
	8.6–13	+2.6			
	≥ 13	+4.0			




Figura 2: Desempeño del scorecard de puntos en la muestra out-of-time (AUROC 0.674, KS 0.265).

La mora observada por decil de score (Tabla 5) documenta una pendiente de riesgo casi perfecta: el decil de menor riesgo tiene mora de 2.1 % frente a 19.6 % en el decil más riesgoso (lift de 2.2).

Tabla 5: Tasa de mora por decil de score (OOT). Decil 1 = menor riesgo.

Decil	1	2	3	4	5	6	7	8	9	10
Mora (%)	2.11	4.70	4.38	5.21	8.09	8.14	11.70	11.16	15.22	19.57
Lift	0.23	0.52	0.49	0.58	0.90	0.90	1.30	1.24	1.69	2.17

4.3 Política de aprobación al 25 %

La Tabla 6 compara la política del scorecard frente a las de referencia sobre la muestra OOT. El presupuesto es el mismo en los tres casos: **25 % del monto solicitado** (US\$ 133.7 millones).

Tabla 6: Resultado de la política de aprobación del 25 % (muestra OOT).

Política	Aprobados	Monto aprobado (US\$)	Buenos	Malos	Morosidad
Scorecard (modelo)	9,447	133,668,150	9,107	340	3.6 %
Selección aleatoria	9,402	133,667,875	8,574	828	8.8 %
Aprobar todos	37,450	534,672,725	34,069	3,381	9.0 %

Lectura de negocio. El mismo presupuesto que produce 828 créditos incobrables si se elige al azar, o 3,381 si se origina sin selección, genera solo **340 créditos malos** cuando la selección la hace el scorecard. En términos de monto, los 340 malos concentran aproximadamente US\$ 4.9 millones de exposición incobrable frente a US\$ 11.4 millones de la política aleatoria: una **reducción de 57 %** en el capital en riesgo, con un **ahorro de unos 2.5 % del presupuesto total** evitando créditos que habrían incumplido.

5 Conclusiones y recomendaciones

Conclusiones.

- El proxy de cargo a pérdida es un fenómeno de riesgo válido y consistente: la mora estimada es monótona en la calificación interna y alcanza 9.6 % sobre 84,739 préstamos resueltos.
- La regresión logística, el random forest y XGBoost tienen poder discriminativo comparable (AUROC 0.69–0.70); la logística fue la más estable en validación out-of-time y XGBoost la mejor calibrada.
- El scorecard de cuatro variables conserva 97 % del poder del modelo completo (AUROC 0.674 vs 0.698) con total interpretabilidad, lo que lo hace auditable y viable regulatoriamente.
- Bajo la restricción del 25 %, la selección por score reduce la mora aprobada de 9.0 % a 3.6 % (2.5 veces menos incobrables), y de 8.8 % (aleatorio) a 3.6 %.

Recomendaciones.

1. **Gobierno del modelo:** monitorear KS y Gini mensualmente sobre vintages nuevos; recalibrar el scorecard si el KS cae más de 30 % relativo o si las tasas observadas se desvían más de ± 30 %.
2. **Expansión de variables:** incorporar buró externo (FICO/ VantageScore), monto disponible en tarjetas y comportamiento de pagos para elevar el poder hacia AUROC ≥ 0.75 .
3. **Regla de corte explícita:** además del presupuesto del 25 %, fijar un score mínimo de aceptación (por ejemplo, $s \geq 640$) para blindar la política contra sobre-concentración.
4. **Censura:** incorporar análisis de supervivencia / modelos de incumplimiento por horizonte fijo (12 y 24 meses) para usar toda la información de los créditos activos.
5. **Precio diferencial:** segmentar la tasa de interés por tramo de score (risk-based pricing) para compensar el riesgo residual del decil más alto aprobado.

Reproducibilidad

El código completo está en el repositorio `src/`:

```
python scripts/run_pipeline.py    # ejecuta el pipeline completo
```

La ejecución genera todas las tablas y figuras de este documento en `reports/`, así como el archivo `resumen_metricas.json` con las métricas consolidadas. Los cuadernos `notebooks/01*_*.ipynb` y `notebooks/02*_*.ipynb` documentan el análisis exploratorio y el modelado paso a paso.

Anexo: notas metodológicas

El archivo de datos original (`loan_ejercicio.xlsx`) y su diccionario (`LCDataDictionary.xlsx`) permanecen bajo `data/raw/`. La muestra de desarrollo excluye créditos activos (censurados) para evitar subestimar la mora; el lector debe interpretar todas las tasas como *tasas sobre préstamos resueltos*. La validación temporal sigue la práctica de vintages de la industria y evita optimismo por *look-ahead*.