

Modelo de Decisión para la Aprobación de Créditos y Segmentación de Riesgo

Informe técnico final

Autor: **Orlando Barcena Romero**

Resumen ejecutivo: se desarrolla un modelo estadístico de aprobación crediticia que acepta únicamente 25 % de las solicitudes recibidas y clasifica a los aprobados en segmentos de riesgo *Bueno* y *Malo*. Con regresión logística sobre variables de solicitud y validación en muestra de test, el modelo alcanza un AUROC de **0.746**, excluye de la cartera al **84 %** de los préstamos incumplidos y reduce un tercio la morosidad de la cartera frente al modelo de reglas de la práctica tradicional de la asignatura.

Índice

1. Introducción y planteamiento del problema	2
2. Marco teórico	2
2.1. Riesgo de crédito y probabilidad de incumplimiento	2
2.2. Modelo de regresión logística	2
2.3. Scorecard crediticio	3
2.4. Métricas de capacidad discriminadora	3
3. Datos	3
3.1. Fuente y alcance	3
3.2. Preprocesamiento	4
3.3. Estadística descriptiva	4
4. Metodología	5
4.1. Diseño experimental	5
4.2. Variables del modelo (sin leakage)	5
4.3. Estimación y scorecard	5
4.4. Umbrales operativos	6
4.5. Sistemas de referencia: modelo de reglas	6
5. Resultados	6
5.1. Capacidad discriminadora	6
5.2. Política de aprobación al 25 %	7
5.3. Sub-segmentación de los aprobados	9
5.4. Comparación con el modelo de reglas	10
6. Discusión	10
7. Conclusiones y trabajo futuro	10

1. Introducción y planteamiento del problema

El otorgamiento de crédito es la actividad central de instituciones financieras y aseguradoras de cartera, y su rentabilidad depende de un equilibrio fundamental: *aprobar más solicitudes implica mayor volumen de negocio, pero también mayor exposición a incumplimiento*. La función actuarial participa en este equilibrio mediante la **medición y administración del riesgo de crédito**, definiendo políticas de originación basadas en la solvencia del solicitante.

En el presente proyecto se plantea un escenario operativo con una restricción explícita de política:

*La institución solo puede aprobar el 25 % de las solicitudes de crédito que recibe, y requiere clasificar a los aceptados en dos segmentos: **Buenos** (riesgo bajo, tratamiento preferente) y **Malos** (riesgo controlado, seguimiento especial).*

Esta restricción es común en entornos de *capacidad de fondeo limitada* o de *apetito de riesgo* definido por la alta dirección. El problema se descompone en dos tareas complementarias:

- T1. Selección.** Elegir exactamente al 25 % de solicitantes con el menor riesgo de incumplimiento.
- T2. Segmentación.** Dentro de los aprobados, separar a los clientes de perfil *Bueno* de los de perfil *Malo* para administrar diferencialmente la cartera (tasas, límites, monitoreo y provisiones).

El trabajo se desarrolla sobre datos públicos de préstamos personales de Lending Club, y constituye una evolución profesional del ejercicio de reglas de decisión realizado en clase: se conserva el objetivo de negocio, pero la selección se funda en un **modelo estadístico validado** en lugar de criterios heurísticos.

La estructura del informe es la siguiente: la Sección 2 presenta el marco teórico del riesgo de crédito y de las métricas de capacidad discriminadora; la Sección 3 describe los datos; la Sección 4 detalla la metodología, incluida la construcción de umbrales operativos; la Sección 5 reporta los resultados; la Sección 6 discute sus implicaciones y limitaciones; y la Sección 7 cierra con conclusiones y trabajo futuro.

2. Marco teórico

2.1. Riesgo de crédito y probabilidad de incumplimiento

El riesgo de crédito es la probabilidad de que un deudor no cumpla con sus obligaciones de pago conforme a lo pactado [5, 1]. La herramienta actuarial estándar para administrarlo es el **modelo de scoring**, que asigna a cada solicitante un puntaje proporcional a su riesgo estimado [2]. En la práctica se identifican tres etapas: *originación* (decisiones de aceptación), *comportamiento* (gestión de la cartera en vigor) y *cobranza*.

2.2. Modelo de regresión logística

Sea $Y \in \{0, 1\}$ el estado del préstamo ($Y = 1$ si es *malo*) y $\mathbf{x}$ el vector de características del solicitante. El modelo de regresión logística postula

$$P(Y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta^\top \mathbf{x})}}, \quad (1)$$

estimándose β_0, β por máxima verosimilitud. Su popularidad en la industria se debe a que es *calibrado* (las probabilidades estimadas son directamente utilizables), *interpretable* (coeficientes con signo económico claro) y *estable* frente a muestras pequeñas, además de servir de base para *scorecards* cuadráticos [2].

2.3. Scorecard crediticio

Un scorecard transforma la probabilidad del modelo en una escala aditiva de puntos comparable al puntaje FICO:

$$\text{Score} = \text{offset} - \text{factor} \times \ln\left(\frac{p}{1-p}\right), \quad (2)$$

donde $p/(1-p)$ es el *odds* de incumplimiento. El parámetro factor fija cuántos puntos valen dichas probabilidades (20 puntos por duplicar el odds es la convención de la industria) y offset ancla la escala a un punto de referencia. Así, **mayor puntaje implica menor riesgo** y los umbrales de decisión se expresan en puntos, lenguaje con el que operan las áreas de crédito y cumplimiento.

2.4. Métricas de capacidad discriminatoria

La capacidad del score para separar buenos de malos se mide con:

- **AUROC** (área bajo la curva ROC): probabilidad de que el modelo asigne mayor riesgo a un incumplido elegido al azar que a un cumplido [4]. Va de 0.5 (azar) a 1 (separación perfecta); en aplicaciones crediticias valores entre 0.70 y 0.80 se consideran buenos [3].
- **GINI**: transformación lineal del AUROC, $\text{GINI} = 2 \text{AUROC} - 1$; se interpreta como la proporción de la distribución de malos capturada por encima del azar.
- **KS** (Kolmogorov–Smirnov): máxima distancia vertical entre las distribuciones acumuladas de buenos y malos ordenadas por el score; mide la separación alcanzada en el punto más favorable del ordenamiento.

Adicionalmente se reportan **métricas de negocio** que conectan el modelo con la restricción operativa: tasa de aprobación, tasa de incumplimiento en la cartera aprobada y en la rechazada, y *captura de malos* (proporción de incumplidos excluidos de la cartera).

3. Datos

3.1. Fuente y alcance

La información proviene de la base pública de préstamos personales de **Lending Club**, originados entre 2007 y 2015. El archivo *LCDataDictionary* documenta 80 variables; la base de trabajo contiene 42 variables y **292,849** solicitudes. Para el análisis se conservan las variables de la solicitud (identidad del solicitante y de la operación) y las de desempeño del préstamo (pagos recibidos), que permiten construir la variable objetivo.

3.2. Preprocesamiento

El pipeline de preparación de datos (`00_preprocess.py`) realiza:

1. **Parseo de fechas** (emisión y origen del historial crediticio), independiente del *locale* del sistema, para derivar la *antigüedad del historial* en meses.
2. **Depuración de amplitudes**: recorte de valores extremos no plausibles (DTI, tasas, utilización de líneas) y conversión de tipos.
3. **Ingeniería de variables**: codificación ordinal de `grade` y `emp_length`, logaritmos de montos e ingresos, y banderas de información faltante.
4. **Definición del objetivo**: un préstamo es *malo* si la **recuperación de principal** (`total_rec_prncp/funded_a`) es inferior a **70 %**; *bueno* en caso contrario.

Los valores faltantes se imputan con la **mediana** dentro del pipeline de modelado, ajustada únicamente sobre la muestra de entrenamiento, lo que evita fuga de información hacia la muestra de validación.

3.3. Estadística descriptiva

La Tabla 1 compara los perfiles de buenos y malos préstamos, y la Figura 1 muestra la tasa de incumplimiento observada por calificación crediticia.

Tabla 1: Perfil comparativo de buenos y malos préstamos

Variable (promedio)	Bueno ($n = 81,834$)	Malo ($n = 211,015$)
Monto solicitado (USD)	13,246	15,342
Tasa de interés (% anual)	13.24	13.26
Ingreso anual (USD)	73,543	75,558
Relación deuda-ingreso (%)	16.17	18.89
Morosidades en 2 años	0.24	0.34
Meses desde última morosidad	35.21	33.73
Antigüedad del historial (m)	184.6	200.7
Utilización de líneas (%)	53.8	55.6
Recuperación de principal (%)	97.3	20.8




Figura 1: Tasa de mal préstamo por calificación crediticia. La tasa crece monótonamente de A a G, confirmando que la calificación del originador resume riesgo, aunque con traslape suficiente para que un modelo estadístico agregue valor.

La tasa global de préstamos malos es de **72.1 %**. Este valor es alto porque la base incluye operaciones de la crisis 2008–2009 y el criterio de recuperación es exigente; no representa la morosidad promedio de la industria, sino la definición operativa de este ejercicio.

4. Metodología

4.1. Diseño experimental

Se divide la base en entrenamiento (70 %) y test (30 %) con estratificación por la variable objetivo y semilla fija (42), de modo que los umbrales operativos se calibran exclusivamente con información de entrenamiento y se evalúan en muestra no vista. La proporción de malos es idéntica en ambas muestras (72.1 %).

4.2. Variables del modelo (sin leakage)

Solo se utilizan variables **disponibles al momento de la solicitud**; quedan excluidas todas las variables de resultado (pagos recibidos, recuperaciones, saldos). La matriz final contiene **44** variables: 22 numéricas (monto, tasa, DTI, morosidades, antigüedad del historial, utilización de líneas, banderas de faltante, etc.) y 22 dummies derivadas de `home_ownership`, `verification_status` y `purpose`. Todas se estandarizan dentro del pipeline.

4.3. Estimación y scorecard

Se estima la regresión logística (1) y se transforma al scorecard (2) con factor $= 20 / \ln 2 \approx 28.85$ (20 puntos por duplicación de odds) y un punto de anclaje tal que el umbral de aprobación coincida con $\text{Score} = 600$.

4.4. Umbrales operativos

Sobre la muestra de entrenamiento:

1. **Aprobación:** $p^* = Q_{0.25}(\hat{p}_{train})$, el cuantil 25 % de las probabilidades de incumplimiento estimadas. Aprobar a los 25 % de solicitantes con $\hat{p} \leq p^*$ equivale al punto de corte $\text{Score} \geq 600$.
2. **Sub-segmentación:** entre los aprobados, el segmento *Bueno* corresponde a los puntajes por encima de la mediana del grupo ($\text{Score} \geq 613$) y el *Malo* al resto.

4.5. Sistemas de referencia: modelo de reglas

Se reproduce el modelo de reglas del ejercicio de clase como referencia: **condición principal** (meses desde la última morosidad ≥ 30 o sin registro) más el cumplimiento de al menos 3 de 4 condiciones secundarias ($\text{DTI} \leq 22$; **grade** = A; sin morosidades en 2 años; recuperación $\geq 70\%$). Se reportan dos variantes:

- **Con recuperación** (variante del ejercicio): incluye la regla de desempeño, lo que constituye *leakage* —usa una variable de resultado para decidir sobre ese mismo resultado— y sobreestima sus métricas.
- **Sin recuperación:** variante operable en la práctica.

5. Resultados

5.1. Capacidad discriminatoria

La Tabla 2 resume las métricas en ambas muestras. El modelo generaliza sin sobreajuste: las métricas son prácticamente idénticas en train y test.

Tabla 2: Métricas de discriminación del scorecard

Muestra	AUROC	GINI	KS
Entrenamiento ($n = 204,994$)	0.7462	0.4924	0.3702
Test ($n = 87,855$)	0.7462	0.4924	0.3700




Figura 2: Curvas ROC del modelo logístico (train y test) y de las reglas del ejercicio. La variante “con recuperación” infla artificialmente el AUC por leakage; la comparación honesta es contra la variante operable (AUC 0.57).

La Figura 3 muestra que los puntajes de buenos y malos se superponen parcialmente con centros separados, y que la política de aprobación ($\text{Score} \geq 600$) concentra a los buenos.




Figura 3: Distribución del puntaje por condición real del préstamo y ubicación de los umbrales de decisión.

5.2. Política de aprobación al 25 %

La Tabla 3 presenta las métricas de negocio en la muestra de test. La tasa de aprobación efectiva es **24.88 %** (objetivo 25 %); la cartera aprobada concentra una tasa de malos (45.8 %) claramente

inferior a la población (72.1 %) y a la de los rechazados (80.8 %).

Tabla 3: Métricas de la política de aprobación en la muestra de test

Indicador	Valor
Solicitudes evaluadas	87,855
Tasa de aprobación	24.88 %
Tasa de malos en aprobados	45.8 %
Tasa de malos en rechazados	80.8 %
Captura de malos (excluidos de cartera)	84.2 %
Tasa de malos del segmento <i>Bueno</i> ($n = 11,091$)	37.5 %
Tasa de malos del segmento <i>Malo</i> ($n = 10,766$)	54.3 %

Matriz de confusión de la política de aprobación (test)




Figura 4: Matriz de confusión de la política de aprobación en test.




Figura 5: Curva de captura: revisando el 25 % de menor riesgo se excluye naturalmente –sin decidir caso a caso– una proporción alta de los malos.

5.3. Sub-segmentación de los aprobados

La Figura 6 compara las tasas de incumplimiento por segmento. El segmento *Bueno* (37.5 %) presenta una calidad sustancialmente superior al *Malo* (54.3 %), lo que valida la sub-segmentación como herramienta de administración de cartera: permite fijar condiciones preferentes al primer grupo y esquemas de monitoreo intensivo al segundo.




Figura 6: Tasa real de mal préstamo por segmento de la política (test).

5.4. Comparación con el modelo de reglas

La Tabla 4 muestra la comparación a igual tasa de aprobación (25 %).

Tabla 4: Comparación de métodos a tasa de aprobación de 25 %

Método	AUROC	Malos en la cartera aprobada
Regresión logística (test)	0.7462	45.8 %
Reglas del ejercicio (sin recuperación)	0.5704	67.8 %
Reglas del ejercicio (con recuperación)	0.8538	28.6 %

El modelo estadístico reduce **un tercio** los incumplimientos de la cartera frente a las reglas operables (de 67.8 % a 45.8 %), con un AUROC superior en 0.18. La variante “con recuperación” parece superior, pero su información no está disponible al momento de decidir: sus métricas son inatendibles y solo se reportan para evidenciar el sesgo del ejercicio original.

6. Discusión

Sobre el leakage del ejercicio original. La regla “recuperación $\geq 70\%$ ” coincide con la definición misma de la variable objetivo: usarla para decidir es equivalente a leer el resultado del préstamo antes de otorgarlo. El trabajo revela este sesgo (AUC 0.85 artificial vs. 0.57 operable) y propone la corrección metodológica.

Sobre la interpretación de la calidad de cartera. Una tasa de malos del 45.8 % en la cartera aprobada puede parecer elevada; sin embargo, debe leerse contra la población (72.1 %): la política casi duplica la calidad de la cartera y excluye al 84 % de los incumplidos con un costo de originación de 25 %. La definición de *malo* (recuperación inferior al 70 %) es exigente y agrupa también préstamos con mora parcial, por lo que el nivel absoluto no es comparable con tasas de *default* regulatorias.

Limitaciones. (i) se utiliza una definición de incumplimiento basada en recuperación, no en estados regulatorios (`loan_status`); (ii) la base no es una muestra aleatoria del mercado y contiene cohortes de la crisis; (iii) el scorecard no incorpora restricciones de capital accionario ni fondeo; (iv) no se realizó análisis de estabilidad temporal por cohortes de emisión.

7. Conclusiones y trabajo futuro

Se construyó un **modelo de decisión crediticia** que cumple la restricción operativa de aprobar el 25 % de las solicitudes con el menor riesgo estimado, y que segmenta a los aceptados en *Buenos* y *Malos* para su administración diferencial. Las conclusiones principales son:

1. El scorecard (regresión logística + escala de puntos, corte en 600) alcanza **AUROC 0.746** y **GINI 0.492** con validación en muestra de test sin sobreajuste.
2. La política aprobó **24.88 %** de las solicitudes y redujo la tasa de malos de la cartera de 72.1 % (población) a **45.8 %**, excluyendo al **84.2 %** de los préstamos incumplidos.
3. La sub-segmentación separa carteras con 37.5 % y 54.3 % de malos, habilitando condiciones preferentes y monitoreo diferenciado.

4. Frente a las reglas de la práctica original, el modelo estadístico reduce un tercio la morosidad de la cartera y detecta y corrige el sesgo por leakage.

Trabajo futuro: (i) redefinir el objetivo con estados regulatorios (**charge off**) y severidad de pérdida; (ii) validación temporal por cohortes; (iii) árboles de decisión y *gradient boosting* como modelos alternativos con *baseline* logístico; (iv) incorporar capital económico y métricas de rentabilidad (pérdida esperada vs. ingreso por interés); (v) simulación de la estabilidad de los umbrales ante escenarios de estrés.

Referencias

- [1] L. Thomas, D. Edelman y J. Croxford. *Credit Scoring and Its Applications*. SIAM Monographs on Mathematical Modeling and Computation, 2002.
- [2] R. Anderson. *The Credit Scoring Toolkit: Theory and Practice for Retail Credit Risk Management and Decision Automation*. Oxford University Press, 2007.
- [3] N. Siddiqi. *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons, 2006.
- [4] J. A. Hanley y B. J. McNeil. “The meaning and use of the area under a receiver operating characteristic (ROC) curve”. *Radiology*, 143(1):29–36, 1982.
- [5] Basel Committee on Banking Supervision. *Studies on the Validation of Internal Rating Systems*. Bank for International Settlements, Working Paper 14, 2005.
- [6] Lending Club. *LCDataDictionary*. Base pública de datos de préstamos personales, disponible en <https://www.lendingclub.com>.

Reproducibilidad

Todo el análisis es reproducible con el pipeline `run_pipeline.py` (etapas 00–03) incluido en el repositorio, usando los datos públicos referidos. Las versiones de las librerías se documentan en `requirements.txt`; la semilla aleatoria (42) fija la división train/test.